

# Diseños factoriales fraccionados

---

Kevin García 1533173  
Alejandro Vargas 1525953  
Alejandro Soto 1532457

24 de marzo de 2019

# Introducción

Los diseños factoriales surgen ante la necesidad de estudiar conjuntamente varios factores obedeciendo a la posibilidad de que el efecto de un factor cambie según los niveles de otros factores, esto es, que los factores interactúen. Estos diseños también se usan cuando se quiere optimizar la respuesta o variable dependiente, es decir, se quiere encontrar la combinación de niveles de los factores que producen un valor óptimo de la variable dependiente.

Si se investiga un factor por separado, el resultado puede ser diferente al estudio conjunto y es mucho más difícil describir el comportamiento general del proceso o encontrar el óptimo.

# Diseño Factorial

Un diseño factorial es un tipo de experimento cuyo diseño permite estudiar los efectos que varios factores pueden tener en una respuesta. Al realizar un experimento, variar los niveles de todos los factores al mismo tiempo en lugar de uno a la vez, permite estudiar las interacciones entre los factores.

# Diseño Factorial

Suponga que tenemos dos factores,  $A$  con  $a$  niveles y  $B$  con  $b$  niveles. Las observaciones de un experimento factorial pueden describirse con un modelo. Hay varias formas de escribir el modelo de un experimento factorial. La forma más utilizada es el modelo de los efectos:

$$y_{ijk} = \mu + \tau_i + \beta_j + (\tau\beta)_{ij} + \varepsilon_{ijk} \quad \left\{ \begin{array}{l} i = 1, 2, \dots, a \\ j = 1, 2, \dots, b \\ k = 1, 2, \dots, n \end{array} \right.$$

# Diseño Factorial

Donde  $\mu$  es el efecto promedio global,  $\tau_i$  es el efecto del nivel  $i$ -ésimo del factor  $A$  de los renglones,  $\beta_j$  es el efecto del nivel  $j$ -ésimo del factor  $B$  de las columnas,  $(\tau\beta)_{ij}$  es el efecto de la interacción entre  $\tau_i$  y  $\beta_j$ , y  $\varepsilon_{ijk}$  es un componente del error aleatorio. Puesto que hay  $n$  replicas del experimento, hay  $abn$  observaciones en total.

# Diseño Factorial

El efecto de un factor se define como el cambio en la respuesta producido por un cambio en el nivel del factor, a este efecto se le conoce como efecto principal porque se refiere a los factores de interés primario en el experimento. Entonces si tenemos dos factores A y B, como en la siguiente tabla:

Cuadro:

<b>Factor B</b>	<b>Factor A</b>	
	<b>bajo</b>	<b>alto</b>
<b>bajo</b>	a	b
<b>alto</b>	c	d

# Diseño Factorial

El efecto principal del factor A es la diferencia entre la respuesta promedio con el nivel alto de A y la respuesta promedio con el nivel bajo de A. Esto es:

$$A = \frac{b + d}{2} - \frac{a + c}{2}$$

Análogamente, el efecto principal del factor B es:

$$B = \frac{c + d}{2} - \frac{a + b}{2}$$

# Diseño Factorial

Si existe interacción entre los factores A y B, el efecto de la interacción se define como la diferencia promedio de los dos efectos del factor A, es decir:

$$AB = \frac{(d - c) - (b - a)}{2}$$

En el diseño factorial de dos factores, ambos factores, A y B son de igual interés, por lo que se prueban las hipótesis acerca de la igualdad de los efectos de los tratamientos de cada factor. Para el factor A:

$$\begin{aligned} H_0 : \tau_1 &= \tau_2 = \dots = \tau_a = 0 \\ H_1 : &\text{Al menos una } \tau_i \neq 0 \end{aligned}$$



# Diseño Factorial

Para el factor  $B$ :

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_b = 0$$


$$H_1 : \text{Al menos una } \beta_j \neq 0$$

También existe interés en determinar si los tratamientos de los factores  $A$  y  $B$  interactúan. Por lo tanto, también querría probarse

$$H_0 : (\tau\beta)_{ij} = 0 \text{ para todas las } i, j$$

$$H_1 : \text{Al menos una } (\tau\beta)_{ij} \neq 0$$

# Porcentaje de inercia explicado




# Resultados para los individuos

- Coordenadas

	Dim.1	Dim.2
1	-1.3143364	0.66717540
2	-0.3841853	0.79937921
3	-1.0565914	0.62799661
4	2.9064639	-0.12345710
5	1.4632792	0.92058312
6	0.4665257	0.06981062
7	-0.2300072	-0.89133817
8	-0.5225866	-1.13568796
9	0.1370254	-0.90435088
10	-1.3937676	-0.67628794
11	-1.7680431	0.54456430
12	1.6962234	0.10161280

# Resultados para los individuos

## ● Nube de individuos




# Resultados para los individuos

- Contribuciones

	Dim.1	Dim.2
1	7.82077792	7.40334197
2	0.66821834	10.62804681
3	5.05418322	6.55937355
4	38.24430069	0.25350113
5	9.69373756	14.09528211
6	0.98534439	0.08105705
7	0.23950776	13.21395346
8	1.23638399	21.45190194
9	0.08500387	13.60259270
10	8.79463025	7.60695852
11	14.15215481	4.93226139
12	13.02575720	0.17172937


# Resultados para los individuos

## ● Contribuciones



# Resultados para los individuos

## ● Contribuciones



# Resultados para los individuos


- Cosenos cuadrados

	Dim.1	Dim.2
1	0.78366123	0.201927428
2	0.10365480	0.448759438
3	0.72290537	0.255377089
4	0.97704556	0.001762857
5	0.65512731	0.259296895
6	0.17896249	0.004007318
7	0.04884725	0.733571370
8	0.16466255	0.777671827
9	0.01490332	0.649165033
10	0.73853508	0.173881625
11	0.88421345	0.083882184
12	0.88317768	0.003169413




# Resultados para los individuos

## ● Cosenos cuadrados



# Resultados para los individuos

## ● Cosenos cuadrados




# Resultados para las variables

- Coordinadas

	Dim.1	Dim.2
Color.intensity	0.8542630	0.28809072
Odor.intensity	0.6141905	0.71649921
Attack.intensity	0.9502405	-0.23400493
Sweet	-0.8979722	-0.07642941
Acid	0.9039337	-0.31789113
Bitter	0.9697080	0.17204423
Pulp	-0.6398293	0.70466313
Typicity	-0.8053443	0.40789439

# Resultados para las variables

- Nube de variables




# Resultados para las variables

- Contribuciones

	Dim.1	Dim.2
Color.intensity	18.104829	7.5645086
Odor.intensity	9.358741	46.7900601
Attack.intensity	22.401565	4.9908234
Sweet	11.162149	0.2970666
Acid	11.310847	5.1391316
Bitter	13.016792	1.5052657
Pulp	5.666961	25.2520138
Typicity	8.978116	8.4611302


# Resultados para las variables

## ● Contribuciones



# Resultados para las variables

## ● Contribuciones



# Resultados para las variables


- Cosenos cuadrados

	Dim.1	Dim.2
Color.intensity	0.7297652	0.082996266
Odor.intensity	0.3772299	0.513371117
Attack.intensity	0.9029570	0.054758309
Sweet	0.8063541	0.005841454
Acid	0.8170961	0.101054769
Bitter	0.9403336	0.029599218
Pulp	0.4093815	0.496550127
Typicity	0.6485794	0.166377831




# Resultados para las variables

## ● Cosenos cuadrados

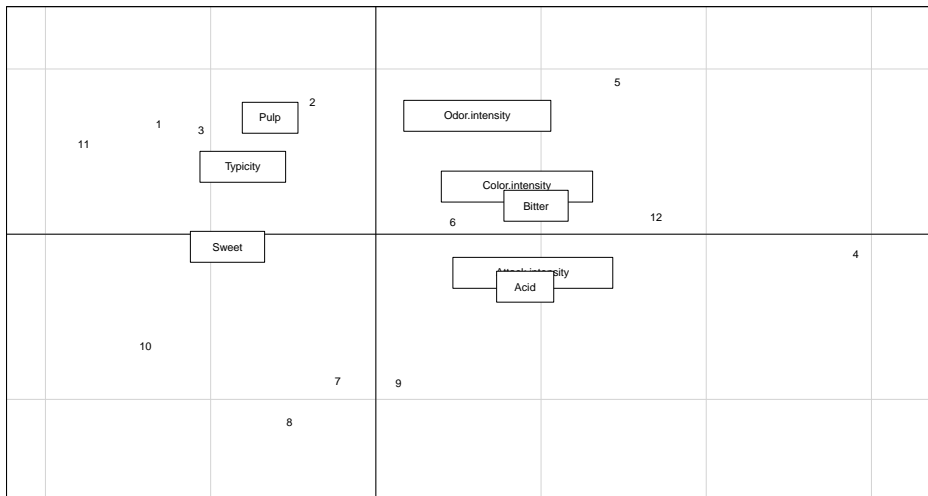


# Resultados para las variables


## ● Cosenos cuadrados



# Representación simultánea



# Nube de los grupos



## Coeficiente Lg

- Coeficiente Lg: Es un indicador del grado de similitud o deformación con respecto a un foco (homotecia) entre los conjuntos de indicadores, y cuando se calcula para un solo conjunto de ellos. Esto se conoce como indicador de la dimensionalidad de la nube, que es igual al número de direcciones ortogonales de inercia no cero, es decir, el número de valores propios no cero. Esta cantidad es 0 cuando todas las variables de un grupo son ortogonales a todas las variables del otro grupo. Es mas alto en cuanto cada una de las variables de un grupo este más relacionada con el conjunto de variables del otro grupo.

Se define por:

$$Lg = \frac{\text{Traza}(S' T)}{\alpha_1^2 \times \lambda_1^2}$$

## Coefficiente Lg

Los coeficientes Lg se pueden observar en la siguiente tabla:

	Percepción previa	Percepción posterior	MFA
Percepción previa	1.0839432	0.7761085	1.0105158
Percepción posterior	0.7761085	1.0384112	0.9857795
MFA	1.0105158	0.9857795	1.0845333

El valor del coeficiente  $Lg_{(P.Previa)} = 1,0839$  para la percepción previa indica que es de dimensionalidad uno, es decir, que puede sintetizarse en un solo factor;  $Lg_{(P.Posterior)} = 1,0384$  indica que la percepción posterior también tiene una dimensión o factor que lo caracteriza. El coeficiente Lg cruzado  $Lg_{(P.Prev,P.Post)} = 0,7761$  indica que estos dos grupos comparten un factor; y finalmente, el coeficiente  $Lg_{(MFA)} = 1,0845$  indica que éste se puede sintetizar como mínimo en un factor.

# Coeficiente Rv de Escoufier

Es una generalización multivariada del coeficiente de correlación de Pearson al cuadrado. Este coeficiente mide el vínculo entre dos grupos o dos matrices de variables. Este coeficiente, al igual que el de correlación de Pearson, se encuentra entre 0 (todas las variables del primer grupo o matriz, son ortogonales a todas las variables del segundo grupo o matriz) y 1 (los dos grupos o matrices son homotéticos)

El coeficiente de RV se define como (Robert y Escoufier, 1976; Schlich, 1996):

$$RV(W_i, W_j) = \frac{T(W_i, W_j)}{[T(W_i, W_i) \cdot T(W_j, W_j)]^{\frac{1}{2}}}$$

## Coefficiente Rv de Escoufier

Donde  $T(W_i, W_j) = \sum_{l,m} w_{l,m}^i w_{l,m}^j$  es un coeficiente de covarianza generalizado entre las matrices  $W_i$  y  $W_j$ ,  $T(W_i, W_i) = \sum_{l,m} w_{l,m}^i{}^2$  es una varianza generalizada de la matriz  $W_i$  y  $w_{l,m}^2$  es el (l,m) elemento de la matriz  $W_i$ .

Los coeficientes Rv se pueden observar en la siguiente tabla:


	Percepción previa	Percepción posterior	MFA
Percepción previa	1.0000000	0.7315340	0.9320054
Percepción posterior	0.7315340	1.0000000	0.9289101
MFA	0.9320054	0.9289101	1.0000000




## Coeficiente $R_v$ de Escoufier

Los valores de los coeficientes  $R_{v(MFA,P.Previa)} = 0,932$  y  $R_{v(MFA,P.Posterior)} = 0,9289$  nos indican que ambos grupos (percepción previa y posterior) tienen una estructura cercana a la de toda la degustación ó en otras palabras, tienen un grado considerable de asociación con el AFM. Es decir, que su representación sobre los planos generados por el AFM es adecuada. Además, entre la percepción previa y posterior el coeficiente  $R_v$  es de 0.7315340 lo que significa que existe un vinculo considerable entre estos dos grupos (algunas de las variables del primer grupo están asociadas con las del segundo grupo).

# Representación superpuesta



# Ejes parciales



## Construcción índice

Las coordenadas de las variables para las dos primeras dimensiones son:

	Dim.1	Dim.2
Color.intensity	0.8581049	0.2236407
Odor.intensity	0.6316557	0.7028833
Attack.intensity	0.9522195	-0.2260020
Sweet	-0.8881581	-0.1346408
Acid	0.9028145	-0.3139184
Bitter	0.9640321	0.1981328
Pulp	-0.6320766	0.7018089
Typicity	-0.8054955	0.3978624

## Construcción índice

El índice para el primer grupo (percepción previa) es:

$$I = 0,8581049Color + 0,6316557Odor + 0,9522195Attack$$

Jugo	Indice
1	11.03415
2	11.823
3	11.16971
4	16.35666
5	14.28656
6	13.58883
7	11.71434
8	11.12588
9	11.61305
10	10.57015
11	10.35774
12	14.9813

# Referencias

- Kassambara, A. & Mundt, F. (2017), factoextra: Extract and Visualize the Results of Multivariate Data Analyses. R package version 1.0.5. \*<https://CRAN.R-project.org/package=factoextra>
- Lê, S., Josse, J. & Husson, F. (2008), 'FactoMineR: A package for multivariate analysis', Journal of Statistical Software 25(1), 1-18.
- Ludovic Lebart, Alain Morineau, M. P. (1995), Statistique exploratoire multidimensionnelle, Dunod, Paris.
- Salamanca, J. A. C. (2017), 'Análisis factorial múltiple para clasificación de universidades latinoamericanas', Comunicaciones en Estadística .

# Referencias

- Wickham, H. (2009), ggplot2: Elegant Graphics for Data Analysis, Springer-Verlag New York. \*<http://ggplot2.org>
- Wickham, H. & Bryan, J. (2018), readxl: Read Excel Files. R package version 1.1.0.  
\*<https://CRAN.R-project.org/package=readxl>
- Zelaya, J. T. (n.d.), ANÁLISIS MULTIVARIADO DE DATOS, Universidad de Costa Rica.